

ĐỒ ÁN 2

KHAI THÁC TẬP PHỔ BIẾN

Frequent Itemset Mining – Nghiên cứu, Cài đặt & Đánh giá

Môn học: Khai thác dữ liệu và ứng dụng

Mã HP: CSC14004

Học kỳ: HỌC KỲ 2 – 2025/2026

Thông tin giảng viên

GV Thực hành: Th.S Nguyễn Thị Thu Hằng

Th.S Nguyễn Ngọc Đức

Th.S Lê Nhật Nam

E-mail: ntthuhang0131@gmail.com

{nnduc, lnnam}@fit.hcmus.edu.vn

Bộ môn: Khoa học máy tính

Tài liệu này dành riêng cho mục đích học thuật.

Mục lục

1	MỤC TIÊU ĐỒ ÁN	2
2	LỰA CHỌN THUẬT TOÁN	2
2.1	Nguồn tham khảo	2
2.2	Quy tắc lựa chọn	3
3	NỘI DUNG BÁO CÁO	3
3.1	Chương 1: Nền tảng lý thuyết	3
3.1.1	Bài toán Frequent Itemset Mining	3
3.1.2	Phân tích thuật toán được chọn	4
3.2	Chương 2: Ví dụ minh họa tay (Step-by-step)	4
3.2.1	Ví dụ 1: Cơ sở	4
3.2.2	Ví dụ 2: Tình huống đặc biệt	5
3.3	Chương 3: Cài đặt	5
3.3.1	Môi trường và công cụ	5
3.3.2	Yêu cầu cài đặt	5
3.4	Chương 4: Thực nghiệm và đánh giá	6
3.4.1	Tập dữ liệu benchmark	6
3.4.2	Thực nghiệm bắt buộc	6
3.4.3	Phân tích kết quả	6
3.5	Chương 5: Ứng dụng	7
4	YÊU CẦU KỸ THUẬT	7
4.1	Về mã nguồn	7
4.2	Về báo cáo PDF	8
5	TỔ CHỨC ĐỒ ÁN VÀ NỘI BÀI	8
6	TIÊU CHÍ CHẤM ĐIỂM	9

1. MỤC TIÊU ĐỒ ÁN

Khai thác tập phổ biến (Frequent Itemset Mining – FIM) là nền tảng của nhiều bài toán khai phá dữ liệu quan trọng, từ luật kết hợp (association rules), phân tích giỏ hàng (market basket analysis) cho đến phát hiện mẫu trong dữ liệu sinh học và web. Đồ án này yêu cầu sinh viên đi sâu vào *một* thuật toán FIM cụ thể – không chỉ dừng lại ở việc sử dụng thư viện có sẵn mà phải **tự cài đặt lại từ đầu**, chứng minh hiểu biết nền tảng và khả năng tối ưu hóa thực tế.

Sau khi hoàn thành, sinh viên đạt được:

- Hiểu sâu cơ sở lý thuyết, cấu trúc dữ liệu và độ phức tạp của thuật toán được chọn.
- Khả năng cài đặt lại một thuật toán khai phá dữ liệu bằng **Julia** (ưu tiên) hoặc Python từ mô tả gốc trong bài báo khoa học.
- Kỹ năng thiết kế thực nghiệm, đo lường hiệu năng và so sánh với cài đặt tham chiếu (SPMF).
- Kỹ năng viết báo cáo kỹ thuật theo chuẩn học thuật.

Ưu tiên Julia

Đồ án **ưu tiên** sử dụng ngôn ngữ **Julia** để cài đặt. Nhóm sử dụng Julia sẽ được cộng **+5 điểm thưởng** vào tổng điểm đồ án. Python được chấp nhận nhưng không nhận điểm thưởng này.

2. LỰA CHỌN THUẬT TOÁN

2.1. Nguồn tham khảo

Sinh viên truy cập trang thư viện SPMF và chọn một thuật toán trong danh mục **Frequent Itemset Mining**:

<https://www.philippe-fournier-viger.com/spmf/index.php?link=algorithms.php>

Các thuật toán hợp lệ bao gồm (nhưng không giới hạn ở) các nhóm sau:

Nhóm	Thuật toán tiêu biểu	Độ khó
Tập phổ biến cơ bản	Apriori, Apriori-TID, AprioriClose	Trung bình
Tập phổ biến dạng cây	FP-Growth, FP-Growth*, HMine, Relim, SLPGrowth	Khó
Tập phổ biến dạng thẳng đứng	Eclat, dEclat, VIPER, Index-BitTableFI	Khó
Tập đóng (Closed)	Charm, Charm-MFI, LCM, DCI_Closed, Zart	Rất khó
Tập tối đại (Maximal)	GenMax, MAFIA, FPMFI	Rất khó
Tập generator	Apriori-Inverse, Pascal	Khó

2.2. Quy tắc lựa chọn

Yêu cầu

- Mỗi nhóm chọn **một** thuật toán duy nhất. Được phép trùng thuật toán giữa các nhóm trong cùng lớp.
- Thuật toán phải có **bài báo gốc** (original paper) có thể tải được – đây là tài liệu kỹ thuật chính mà sinh viên phải đọc và cài đặt dựa vào đó.
- Không sao chép mã nguồn từ SPMF (Java) hay bất kỳ cài đặt sẵn có nào khác. Sinh viên phải **tự viết từ đầu** dựa trên mô tả trong bài báo.
- Nhóm có thể đề xuất một thuật toán FIM không có trong danh sách trên nếu có sự đồng ý của giảng viên.

3. NỘI DUNG BÁO CÁO

Báo cáo được tổ chức thành **5 chương** chính, mỗi chương tương ứng với một phần đánh giá riêng.

3.1. Chương 1: Nền tảng lý thuyết

3.1.1. Bài toán Frequent Itemset Mining

Sinh viên cần trình bày đầy đủ, chính xác các định nghĩa/ định lý và kết quả liên quan đến thuật toán. Ví dụ như:

- Cơ sở dữ liệu giao dịch** (Transaction Database): Định nghĩa hình thức cơ sở dữ liệu $\mathcal{D} = \{T_1, T_2, \dots, T_n\}$ trong đó mỗi $T_i \subseteq \mathcal{I}$ với $\mathcal{I}$ là tập tất cả các item.

- b) **Độ hỗ trợ** (Support): Định nghĩa $sup(X)$ cho một itemset $X \subseteq \mathcal{I}$. Phân biệt support tuyệt đối và tương đối.
- c) **Tập phổ biến** (Frequent Itemset): Định nghĩa khi nào X là frequent với ngưỡng $minsup$.
- d) **Tập đóng** (Closed Itemset) và **Tập tối đại** (Maximal Itemset): Định nghĩa hình thức và quan hệ giữa ba loại: frequent $\supseteq$ closed $\supseteq$ maximal.
- e) **Tính chất Apriori** (Downward Closure): Phát biểu và chứng minh ngắn gọn tính chất đơn điệu giảm (anti-monotone) của độ support.

Sinh viên có thể bổ sung thêm các kiến thức khác để người đọc có thể hiểu được thuật toán đang được trình bày.

3.1.2. Phân tích thuật toán được chọn

[Bắt buộc] Đây là phần trọng tâm của Chương 1. Sinh viên phải:

- a) **Trình bày ý tưởng cốt lõi**: Mô tả bằng lời trực quan (intuition) tại sao thuật toán hoạt động được, điểm khác biệt so với các thuật toán trước nó là gì.
- b) **Cấu trúc dữ liệu chính**: Mô tả và minh họa cấu trúc dữ liệu đặc trưng mà thuật toán sử dụng (ví dụ: FP-tree cho FP-Growth, tidset/diffset cho Eclat/dEclat, ...). Vẽ hình minh họa cấu trúc đó với ví dụ cụ thể.
- c) **Giải mã (Pseudocode)**: Trình bày giả mã đầy đủ của thuật toán. Sinh viên nên chú thích ý nghĩa từng bước quan trọng để làm rõ ý tưởng đằng sau của thuật toán.
- d) **Phân tích độ phức tạp**:
 - Độ phức tạp thời gian trong trường hợp tốt nhất, trung bình và xấu nhất.
 - Độ phức tạp không gian.
 - Các yếu tố ảnh hưởng chính đến hiệu năng (kích thước CSDL, minsup, chiều rộng giao dịch trung bình, ...).
- e) **So sánh lịch sử**: Đặt thuật toán vào dòng thời gian phát triển của FIM. Nó giải quyết hạn chế gì của các thuật toán trước và để lại hạn chế gì cho các thuật toán sau?

3.2. Chương 2: Ví dụ minh họa tay (Step-by-step)

[Bắt buộc] Sinh viên phải thực hiện **hai ví dụ minh họa** hoàn toàn bằng tay (không dùng máy tính), trình bày từng bước chi tiết:

3.2.1. Ví dụ 1: Cơ sở

Chạy thuật toán trên CSDL đồ chơi gồm 5–7 **giao dịch** và 5–6 **item** với minsup tự chọn. Trình bày:

- Bảng CSDL gốc.
- Toàn bộ các bước trung gian (xây dựng cấu trúc, duyệt cây, giao tidset, ...tùy thuật toán).
- Tập kết quả cuối cùng với support tương ứng.
- Kiểm tra chéo (cross-check) kết quả bằng cách liệt kê thủ công tất cả itemset phổ biến.

3.2.2. Ví dụ 2: Tình huống đặc biệt

Thiết kế một CSDL có **tình huống đặc biệt** liên quan đến thuật toán (ví dụ: cây FP-tree chỉ có một nhánh – single path; diffset âm hoàn toàn; tập đóng trùng với tập tối đại; ...). Chỉ ra cách thuật toán xử lý tình huống đó và tại sao đây là trường hợp đặc biệt quan trọng.

3.3. Chương 3: Cài đặt

3.3.1. Môi trường và công cụ

Ưu tiên Julia

Ngôn ngữ ưu tiên: **Julia** (phiên bản ≥ 1.9). Sinh viên sử dụng Julia nên tận dụng các đặc trưng ngôn ngữ như multiple dispatch, BitArray, generator expressions và DataStructures.jl thay vì viết theo phong cách Python/Java.

Nếu dùng Python, yêu cầu Python ≥ 3.9 và chỉ được sử dụng numpy, pandas, bitarray – **không được** dùng mlxtend, efficient-apriori hay bất kỳ thư viện FIM nào.

3.3.2. Yêu cầu cài đặt

[Bắt buộc] Sinh viên phải cài đặt từ đầu (from scratch) theo các bậc yêu cầu sau:

- **Cài đặt cơ bản:** Cài đặt đúng thuật toán, xuất ra tất cả frequent itemset và support tương ứng. Kết quả phải khớp hoàn toàn với SPMF trên cùng input.
- **Tái tạo đúng kết quả:** Kiểm thử tự động (unit test) trên ít nhất 5 CSDL khác nhau (bao gồm CSDL từ ví dụ tay ở Chương 2). Báo cáo tỉ lệ đúng so với kết quả tham chiếu từ SPMF.
- **Tối ưu hóa bộ nhớ và tốc độ:** Áp dụng ít nhất **một kỹ thuật tối ưu** phù hợp với thuật toán (ví dụ: sử dụng bitset/BitArray cho tidset, nén FP-tree, tỉa nhánh sớm, ...). Đo lường và báo cáo mức cải thiện so với bản cơ bản.
- **Xử lý đầu vào/đầu ra:** Hỗ trợ đọc file định dạng SPMF (.txt dạng *itemset per line, space-separated*) và xuất kết quả theo cùng định dạng. Thêm tham số dòng lệnh cho minsup và đường dẫn file.

3.4. Chương 4: Thực nghiệm và đánh giá

3.4.1. Tập dữ liệu benchmark

Sinh viên phải thực nghiệm trên **ít nhất 4 tập dữ liệu benchmark** phổ biến trong cộng đồng FIM. Các tập dữ liệu có thể tải tại [trang SPMF Datasets](#) hoặc [FIMI Repository](#):

Tập dữ liệu	#Trans.	#Items	AvgLen	Đặc điểm
Chess	3.196	75	37.0	Dày đặc (dense), itemset dài
Mushroom	8.124	119	23.0	Dày đặc, nhiều item
Retail	88.162	16.47	10.3	Thưa (sparse), thực tế
Accidents	340.183	468	33.8	Rất lớn, dày đặc
T10I4D100K	100.000	870	10.1	Tổng hợp, thưa

3.4.2. Thực nghiệm bắt buộc

[Bắt buộc] Sinh viên phải thực hiện đầy đủ các thực nghiệm sau và trình bày bằng biểu đồ rõ ràng:

- Kiểm tra tính đúng đắn (Correctness):** Với mỗi tập dữ liệu, so sánh số lượng frequent itemset và support của từng itemset giữa cài đặt của nhóm và SPMF. Báo cáo: (i) tỉ lệ itemset khớp hoàn toàn; (ii) nếu có sai lệch, phân tích nguyên nhân.
- Thời gian chạy theo minsup:** Với mỗi tập dữ liệu, vẽ đồ thị **thời gian chạy (ms)** theo **minsup** giảm dần (ít nhất 5–7 điểm minsup khác nhau, từ cao xuống thấp). So sánh đường cong của cài đặt nhóm với SPMF trên cùng đồ thị.
- Số lượng frequent itemset theo minsup:** Vẽ đồ thị số lượng frequent itemset được sinh ra theo minsup. Nhận xét mối quan hệ giữa minsup và output size, so sánh trên các tập dữ liệu dày/thưa.
- Sử dụng bộ nhớ:** Đo và báo cáo mức sử dụng RAM tối đa (peak memory) cho mỗi tập dữ liệu tại minsup trung bình. So sánh giữa bản cơ bản và bản tối ưu của nhóm.
- Khả năng mở rộng (Scalability):** Chọn một tập dữ liệu lớn (Retail hoặc Accidents). Tạo các tập con có kích thước 10%, 25%, 50%, 75%, 100% giao dịch. Vẽ đồ thị thời gian chạy theo kích thước CSDL. Nhận xét xu hướng tuyến tính hay phi tuyến.
- Ảnh hưởng của độ dài giao dịch trung bình:** Nếu thuật toán bị ảnh hưởng bởi độ dài giao dịch, thiết kế thực nghiệm minh chứng điều này bằng cách tạo CSDL tổng hợp với độ dài giao dịch tăng dần.

3.4.3. Phân tích kết quả

Với mỗi thực nghiệm, sinh viên không chỉ trình bày số liệu mà phải:

- **Giải thích kết quả** dựa trên lý thuyết đã trình bày ở Chương 1.

- Xác định **điểm mạnh và điểm yếu** của cài đặt so với SPMF.
- Đề xuất **ít nhất 2 hướng tối ưu hóa** cụ thể có thể áp dụng tiếp theo.

3.5. Chương 5: Ứng dụng

Sinh viên chọn **một** ứng dụng thực tế và áp dụng thuật toán đã cài đặt:

- Phân tích giỏ hàng (Market Basket Analysis):** Dùng tập dữ liệu bán lẻ thực (Retail, Groceries, hoặc tự tìm). Từ frequent itemset, sinh luật kết hợp (association rules) với $sup() \geq minsup$ và $conf(X \Rightarrow Y) \geq minconf$. Trình bày top-10 luật theo lift và giải thích ý nghĩa kinh doanh.
- Phát hiện mẫu trong log hệ thống:** Áp dụng cho tập log sự kiện (event log). Tìm các tổ hợp sự kiện xuất hiện cùng nhau thường xuyên. Thảo luận về khả năng phát hiện lỗi hay hành vi bất thường.
- Phân tích dữ liệu sinh học:** Áp dụng cho dữ liệu genome hoặc protein sequence đã mã hóa thành dạng transaction. Thảo luận về ý nghĩa sinh học của các pattern được tìm thấy.

Lưu ý

Phần ứng dụng không được dùng kết quả từ thư viện FIM có sẵn – sinh viên phải dùng **chính cài đặt của nhóm** để thu kết quả.

4. YÊU CẦU KỸ THUẬT

4.1. Về mã nguồn

- **Ngôn ngữ:** Julia ≥ 1.9 (ưu tiên hơn so) hoặc Python ≥ 3.9 . Không được dùng thư viện FIM.
- **Reproducibility:** Đặt seed ngẫu nhiên cố định. Mọi kết quả phải tái sản xuất được khi chạy lại.
- **Kiểm thử:** Có bộ unit test tự động. Chạy `julia --project test/runtests.jl` (hoặc `pytest`) phải pass toàn bộ.
- **Hiệu năng:** Cài đặt Julia phải tránh các *performance anti-patterns*: không dùng global variables không typed, không dùng abstract type trong hot loop, tận dụng `@inbounds` và `@simd` khi phù hợp.
- **Tài liệu:** README phải có hướng dẫn cài đặt môi trường, cách chạy và ví dụ sử dụng cụ thể.

4.2. Về báo cáo PDF

Báo cáo phải đáp ứng:

- Viết bằng **tiếng Việt**. Thuật ngữ kỹ thuật tiếng Anh giữ nguyên lần đầu, có chú thích.
- Mọi công thức toán phải dùng ký hiệu chuẩn và được giải thích biến.
- Mọi hình vẽ, bảng biểu phải có **chú thích (caption)** và được tham chiếu trong văn bản.
- Tối thiểu **15 trang** không kể tài liệu tham khảo và phụ lục.
- Mục **Tài liệu tham khảo** phải bao gồm bài báo gốc của thuật toán và ít nhất 3 tài liệu liên quan khác.

5. TỔ CHỨC ĐỒ ÁN VÀ NỘI BÀI

Nội dung nộp bài:

- **Định dạng nộp:** File nén Group_ID.zip.
- **File lớn:** Nếu vượt 25MB, tải dữ liệu lên Google Drive và cung cấp link trong README.
- **Notebook phải sạch:** Restart & Run All trước khi nộp.
- **Kiểm thử phải pass:** Chạy bộ test và đính kèm output của lần chạy cuối vào README.

Cấu trúc thư mục gợi ý:

```
1 Group_ID/  
2 |-- README.md  
3 |-- Project.toml # (Julia) hoặc requirements.txt (Python)  
4 |-- src/  
5 |   |-- algorithm/      # Cài đặt chính  
6 |   |-- structures.jl    # Cấu trúc dữ liệu  
7 |   |-- utils.jl        # Tiện ích  
8 |-- tests/  
9 |   |-- test_correctness.jl  
10 |   |-- test_benchmark.jl  
11 |-- data/  
12 |   |-- toy/            # CSDL nhỏ cho ví dụ tay  
13 |   |-- benchmark/      # CSDL benchmark  
14 |-- notebooks/  
15 |   |-- demo.ipynb  
16 |-- docs/  
17 |   |-- Report.pdf
```

6. TIÊU CHÍ CHẤM ĐIỂM

STT	Tiêu chí	Điểm
	Chương 1 – Nền tảng lý thuyết	20%
1	Định nghĩa hình thức, tính chất Apriori	5%
	Phân tích thuật toán: ý tưởng, cấu trúc dữ liệu, giả mã	10%
	Phân tích độ phức tạp và so sánh lịch sử	5%
	Chương 2 – Ví dụ minh họa tay	30%
2	Ví dụ cơ bản: đúng, đủ bước, kiểm tra chéo	15%
	Ví dụ tình huống đặc biệt + phân tích	15%
	Chương 3 – Cài đặt	25-30%
3	Kết quả đúng so với SPMF	10%
	Unit tests tự động đầy đủ	5%
	Tối ưu hóa có đo lường	10%
	I/O chuẩn SPMF, tham số dòng lệnh	5%
	Chương 4 – Thực nghiệm và đánh giá	20%
4	Kiểm tra correctness trên benchmark	5%
	Biểu đồ thời gian, bộ nhớ, scalability	10%
	Phân tích và đề xuất tối ưu hóa	5%
5	Chương 5 – Ứng dụng thực tế (Optional)	10%
	Kết quả đúng, phân tích ý nghĩa	10%
	Tổng tối đa khi viết bằng Julia	100%
	Tổng tối đa khi viết bằng Python	95%

Rubric chấm điểm phần Cài đặt (Chương 3):

- **Xuất sắc:** Kết quả 100% khớp SPMF, code bằng Julia, tối ưu hóa rõ ràng và đo lường chứng minh cải thiện.
- **Tốt:** Kết quả $\geq 95\%$ khớp SPMF, có tối ưu nhưng chưa đo lường. Code bằng Python hoặc Julia.
- **Đạt:** Kết quả $\geq 80\%$ khớp SPMF trên các CSDL nhỏ. Code bằng Python hoặc Julia.
- **Chưa đạt:** Kết quả chưa đúng, hoặc phát hiện sao chép mã nguồn từ cài đặt có sẵn.

Lưu ý quan trọng:

- **Liên chính học thuật:** Sao chép mã nguồn từ bất kỳ nguồn nào (kể cả SPMF, GitHub, ChatGPT) dẫn đến điểm 0 toàn bộ đồ án.
- **Sử dụng AI:** Cho phép sinh viên dùng bất kỳ AI hỗ trợ viết code nào như Claude/ Copilot/ Codex/ Cursor nhưng sinh viên phải hiểu và có khả năng giải thích được bài làm.